# dlbs Mini-Challenge-Titel

## Namen der Teammitglieder

13. April 2023

# 1 Allgemeine Bemerkungen zur Aufgabenstellung

Wählt eine Fragestellung aus den Gebieten Bild- bzw. Signalverarbeitung, welche ihr in dieser Mini-Challenge bearbeiten möchtet. Die Fragestellung soll durch Objekterkennung, Bildsegmentierung, Instanzsegmentierung oder Signalvorhersage mittels Deep Learning implementiert lösbar sein. Die Programmiersprache kann frei gewählt werden. Das Lösungsvorgehen der Mini-Challenge basiert auf den Artikeln:

- How to Avoid Machine Learning Pitfalls: A Guide for Academic Researchers [Lon23]
- A Recipe for Training Neural Networks [Kar19]

#### 1.1 Zusammenarbeit

Die Mini-Challenge-Arbeit wird in 2-er-Teams abgegeben. Ausnahmen wie Einzelarbeiten sind mit den DS Fachexpert:innen zu besprechen. Bei der Abgabe muss für gewisse markierte Fragestellungen ausgewiesen werden, wer diese Teilaufgabe durchführte. Die Studierenden dürfen für diese Mini-Challenge mit anderen Teams zusammenarbeiten, aber jedes Team reicht eine einzigartige Abgabe ein.

# 1.2 Zeitplanung und Termine

- 5 Arbeitswochen Bearbeitungszeit (Ausgabe Montag, Abgabe Freitag)
- Meilenstein 1: Pitches und zusätzliches Bewertungskriterium in 2. Sprechstunde nach Mini-Challenge Start
- Meilenstein 2: Demos in letzter Sprechstunde vor Mini-Challenge Ende
- Meilenstein 3: Finale Abgabe der schriftlichen Dokumentation (siehe 1.3)

Siehe Kalender auf Spaces für Termine.

## 1.3 Abgaben

Dokumentiert eure Lösung der Mini-Challenge in geeigneter Form inkl. abschliessender Reflexion. Die Daten müssen nicht abgegeben werden. Der Lösungsweg muss aber nachvollziehbar sein und ausgewählte Daten müssen visualisiert sein. Falls vorhanden, den Link zu den Daten angeben.

- Report in Deutsch oder Englisch, Overleaf bevorzugt Overleaf Projekt mit Pro-Featrues kann bei DS Fachexpert:in beantragt werden
- GitRepository mit Quellcode

#### 1.4 Pitches und Demos

- Pitches: Fragestellung, Datenlage und Methode; 3 Minuten mit 1 Folie Folie 24h vor Sprechstunde an DS Fachexpert:in senden
- Demos: Recap Fragestellung, Demo und Diskussion der wichtigsten Resultate und Schlussfolgerungen; 5 Minuten mit anschliessenden Q&A
- Online Teilnahme auf Anfrage möglich

#### Zusammenfassung

TASK: Zusammenfassung der Fragestellung, Datenlage, ML Approaches und wichtigsten Resultate inkl. Kennzahlen. Ca. 200 Wörter.

# 2 Fragestellung

TASK: Beschreibt die Ausgangslage und Anwendungsdomäne eurer Fragestellung. Formuliert dazu explizit Hypothese(n), Forschungsfragen oder Ziele. Hier soll das WAS eurer Mini-Challenge beschrieben werden. Ca. 100-200 Wörter.

# 3 Datenlage

TASK: Wählt einen Datensatz mittels welchem die Fragestellung gelöst werden kann. Es können Bilder (2D, 3D), Videos, Signale aus Sensordaten, Punktewolkendaten, Audiodaten oder ähnlich verwendet werden. Es kann ein öffentlich verfügbarer Datensatz, ein eigener Datensatz sowie ein Datensatz aus einem Geschäftsbetrieb sein. Die Daten müssen nicht mit den DS Fachex-pert:innen geteilt werden, sofern der Lösungsweg nachvollziehbar ist. Da wir in dieser Mini-Challenge ein supervised Problem lösen, sollen Ground Truth Daten bzw. Labels vorhanden sein oder mit geringem Aufwand generiert werden können. Bemerkung: Für diese Mini-Challenge kann mit einem «zu kleinen» Datensatz gearbeitet werden. In einem solchen Falle, soll dieser Punkt entsprechend diskutiert werden. Beschreibt die Datenlage in ca. 100-200 Wörtern.

# 4 Methoden/Vorgehen

TASK: Beschreibt und diskutiert die Wahl eurer Lösungsansätze (Baseline, DL Architekturen, Evaluation) gemäss eurer Fragestellung. D.h., warum habt ihr was WIE gemacht? Ca. 300-500 Wörter. Die folgenden Teilkapitel sollen direkt in einem Notebook beantwortet werden.

## 4.1 Datenanalyse

TASK: Führt eine Datenanalyse anhand dieser drei Schritte durch [Kar19]:

- Prüft die Daten mittels visueller Inspektion
- Erfasst ein qualitatives Verständnis der Daten
- Analysiert die Daten quantitativ (mittels Code)
- Befolgt für die Datenanalyse Richtlinien von [Lon23] und diskutiert pro Person 1 Richtlinie:
  - Do take the time to understand your data
  - Don't look at all your data
  - (Do make sure you have enough data)
  - Do talk to domain experts
  - Do survey the literature
  - Do think about how your model will be deployed
  - Don't allow test data to leak into the training process

# 4.2 Setup eines Training-Evaluations-Code-Skeletts inkl. Baseline

TASK:

- Richtet ein Code-Skelett für die Trainings-Evaluations-Zyklen ein
- Wählt ein einfaches Modell als Baseline, geeignete Metriken für die Evaluation der Netzwerke und diskutiert die Wahl inkl. Parameter. Die Baseline soll trainiert/generiert, analysiert und visualisiert werden (Loss, Predictions etc.).
- Definiert pro Person 1-2 Ablationstests zu den Hypothesen/Fragestellungen, welche durchführt und verifiziert werden.

- Befolgt und diskutiert pro Person 1 ausgewählter weiterer Aspekte aus [Kar19]
- Befolgt zudem für das Trainings-Evaluations-Skelett Richtlinien von [Lon23] diskutiert pro Person jeweils 1 Richtlinie:
  - Do use an appropriate test set
  - Do use a validation set
  - Do save some data to evaluate your final model instance
  - Don't use accuracy with imbalanced data sets
  - Do evaluate a model multiple times
  - Don't do data augmentation before splitting your data
  - Don't allow test data to leak into the training process

### 4.3 Overfit

#### TASK:

- Fokussiert auf den Loss des Trainingssets
- Fügt schrittweise zusätzliche Komplexitäten ein und dokumentiert diese
- Wählt pro Person individuell eine Modell-Architektur zur Lösung eurer Fragestellung aus und führt ein Overfitting gemäss [Kar19] durch. Wählt pro Person jeweils 2 unterschiedliche Aspekte von [Kar19] aus, welche ihr implementiert bzw. durchführt und diskutiert.
- Befolgt für das Overfitting Richtlinien von [Lon23] und besprecht pro Person 1 Richtlinie:
  - Don't use inappropriate models
  - Do try out a range of different models
  - Do evaluate a model multiple times
  - Don't do data augmentation before splitting your data
- Optionale Bonusaufgabe: Vergleicht und evaluiert eine zusätzliche DL Architektur

### 4.4 Regularize

#### TASK:

- Gewinnt an Validierungsgenauigkeit durch Verzicht auf gewisse Trainingsgenauigkeit
- Arbeitet pro Person individuell mit eurem Modell weiter und führt pro Person 2 Regularisierungsexperimente gemäss [Kar19] durch
- Vergleicht eure Modelle in geeigneter Weise und befolgt dabei die Richtlinien von [Lon23] diskutiert pro Person 1 Richtlinie:
  - Do evaluate a model multiple times
  - Don't assume a bigger number means a better model
  - Do use statistical tests when comparing models
  - Do correct for multiple comparisons
  - Don't always believe results from community benchmarks
  - Do be transparent
  - Do report performance in multiple ways
  - Do be careful when reporting statistical significance
  - Do look at your models
- Wählt eines eurer Modelle als bestes aus und diskutiert die Entscheidungsfindung

#### 4.5 Tune

#### TASK:

- Fährt nun gemeinsam mit dem ausgewählten Modell fort. Und führt eine der folgenden Tuning-Varianten durch.
  - Random search
  - Grid search
  - Hyper-param optimization
- Befolgt für das Tuning Richtlinien von [Lon23] diskutiert gemeinsam 1 Richtlinie:
  - Do evaluate a model multiple times
  - Do optimise your model's hyperparameters
  - Do be careful where you optimise hyperparameters and select features

# 4.6 Optionale Bonusaufgabe: Squeeze the Juice Out of It

#### TASK:

- Wählt eine Methode aus dem Bereich:
  - Ensemble models
  - Train longer
- Befolgt dafür Richtlinien von [Lon23] diskutiert gemeinsam 1 Richtlinie:
  - Do consider combinations of models
  - Do evaluate a model multiple times

# 5 Wichtigste Resultate

TASK: Beschreibt eure wichtigsten Resultate in ca. 400-500 Wörtern. Verwendet ggf. Abbildungen.

### 6 Diskussion

#### TASK:

- Diskutiert eure Resultate explizit in Bezug auf eure Fragestellung(en) in ca. 500-600 Wörtern. Mit Diskutieren ist gemeint, Vor- und Nachteile, Chancen und Risiken eures Lösungsweges bzw. der Resultate spezifisch für euren Anwendungsfall zu besprechen. Wie sind die Resultate der Baseline im Vgl. zu den optimierten Modellen? Welche Fälle funktionieren gut, welche nicht? Lässt sich die Fragestellung mit den gewählten Modellen und Daten beantworten?
- Befolgt für die Diskussion die Richtlinien von [Lon23]:
  - Don't generalise beyond the data
  - Don't always believe results from community benchmarks
  - Do be transparent

### 7 Reflexion

TASK: Reflektiert abschliessend in ca. 150-200 Wörtern. Was sind die Schlussfolgerungen für die spezifische Fragestellung? Was ist in dieser Mini-Challenge gut gelaufen? Was würdet ihr das nächste Mal anders machen? Was würdet ihr ggf. in der Aufgabenstellung ändern? Fokus auf fachlicher Reflexion.

### 8 Code

TASK: Zugang zu aufgeräumtem und mit README versehenem Git-Repository. Die Abgabe darf keine auskommentierten Codestellen enthalten (ausser pip install statements). Bemerkung zu Code Kommentaren: Code Kommentare sind hilfreich, wenn sie erklären, weshalb eine Entscheidung getroffen wurde oder weshalb eine Rechnung in der bestimmten Art und Weise ausgeführt wurde oder gemäss welcher Quelle etwas implementiert wurde. In der Praxis wird jedoch bei der Code-Entwicklung oft vergessen, die Code-Kommentare anzupassen. Deshalb sind Kommentare oft obsolete. Auskommentierter Code wird in der Praxis typischerweise nicht getestet und später weiss man nicht mehr, ob dieser noch funktioniert oder nicht. Die Empfehlung von mir lautet deshalb: So viele Kommentare wie nötig, aber so wenige wie möglich. Grundsätzlich sollte der Code so geschrieben sein, dass er selbsterklärend ist.

# 9 Optionale Bonusaufgabe: Lerntagebuch

TASK: Optional darf der Abgabe ein Lerntagebuch beiliegen, welches regelmässig dokumentiert, wie der Lernfortschritt war. Bspw. kurz ein paar Fragen beantworten, analog zu einem Scrum Daily. Was hast du an diesem Tag gemacht? Was ist gelungen? Wo gibt es aktuell Probleme? Wer könnte bei diesen Problemen helfen?

### Literatur

[Kar19] Andrej Karpathy. A recipe for training neural networks, 2019.

[Lon23] Michael A. Lones. How to avoid machine learning pitfalls: a guide for academic researchers, 2023.